

BARCS 이해하기

방법론 자습 가이드: 예제, 객관식 퀴즈, 해설

정현환, 이규원

BARCS 버전 0.2.0

Contents

1	BARCS가 푸는 문제	2
2	샘플링 모델	2
2.1	이항분포에서 베타-이항분포로	2
2.2	시퀀싱 깊이와 생물학적 반복을 분리하는 이유	2
3	회귀 모델	3
4	추정: 실현가능 IRLS	3
5	가이드 하나에 대한 추론	4
6	과분산 조절(기본으로 켜짐)	4
6.1	아이디어	4
6.2	절차	4
7	분모: 계수는 무엇에 대한 상대값인가	5
7.1	라이브러리 전체 총합과 조성 이동	5
7.2	대조군 기반 총합	6
8	음성 대조군 보정	6
9	가이드에서 유전자로	7
9.1	방향성 Stouffer	7
9.2	독립성 문제	7
9.3	실제 신호에 속지 않고 r 을 추정하기	7
9.4	실험적 대안	8
10	벤치마크에서 성공을 측정하는 방법	8
11	유의할 한계	8
12	파이프라인 한눈에 보기	8
13	퀴즈	10
14	정답 및 해설	15

1 BARCS가 푸는 문제

폴드(pooled) CRISPR 스크린은 각 가이드 g 와 시퀀싱한 각 라이브러리 i 에 대해 리드 수 K_{gi} 를 만든다. 각 라이브러리에는 매핑된 가이드 리드의 총합 N_i 도 있다. 관심 있는 질문은 가이드 풍부도가 실험 설계, 즉 시간, 정렬된 FACS 빈, 용량, 공여자, 처리, 또는 이들의 상호작용에 따라 어떻게 달라지는가이다.

CB²는 두 그룹에 대해 이 질문에 답했다. BARCS는 같은 샘플링 모델을 유지하되, 두 그룹 평균을 임의의 설계 행렬에 대한 회귀로 바꾼다. 세 가지 객체가 함께 움직인다.

객체	형태	규칙
counts	가이드 $\times$ 라이브러리	원래의 정수 리드 수
totals	라이브러리당 하나	필터링 전 매핑된 가이드 총합 N_i
data	라이브러리당 한 행	counts의 열 순서와 동일

핵심 개념

BARCS는 가이드의 리드 수를 해당 라이브러리 안에서의 비율로 다룬다. 분모 N_i 는 가이드를 하나라도 제거하기 전에 기록한 총합이어야 한다. 가이드를 제거한 뒤 총합을 다시 계산하면, 남은 모든 계수의 의미가 조용히 바뀐다.

2 샘플링 모델

2.1 이항분포에서 베타-이항분포로

어떤 조건의 모든 라이브러리가 정확히 같은 가이드 비율 μ_i 를 가진다면, 시퀀싱은 순수한 이항 샘플링이다: $K_{gi} \sim \text{Binomial}(N_i, \mu_i)$. 실제 라이브러리는 생물학적 반복이므로 진짜 비율 자체가 라이브러리마다 달라진다. BARCS는 라이브러리별 비율 P_i 가 베타분포를 따르도록 한다.

$$K_i | P_i \sim \text{Binomial}(N_i, P_i), \quad P_i \sim \text{Beta}(\mu_i \kappa, (1 - \mu_i) \kappa), \quad \rho = \frac{1}{\kappa + 1}. \quad (1)$$

주변분포로 보면 K_i 는 평균 $N_i \mu_i$, 분산

$$\text{Var}(K_i) = N_i \mu_i (1 - \mu_i) \{1 + (N_i - 1) \rho\} \quad (2)$$

인 베타-이항분포를 따른다. 급내상관 $\rho \geq 0$ 이 과분산(overdispersion)이며, $\rho = 0$ 이면 이항분포로 돌아간다.

2.2 시퀀싱 깊이와 생물학적 반복을 분리하는 이유

N_i 로 나누면 관측 비율 $Y_i = K_i / N_i$ 의 분산은

$$\text{Var}(Y_i) = \mu_i (1 - \mu_i) \left\{ \frac{1 - \rho}{N_i} + \rho \right\} \quad (3)$$

이다. 첫째 항은 시퀀싱 깊이 N_i 가 커지면 줄어들지만, 둘째 항은 줄지 않는다. 라이브러리를 충분히 깊게 시퀀싱하면 남은 불확실성은 생물학적인 것이다.

예제: 더 깊이 시퀀싱해도 거의 도움이 안 된다

$\mu = 10^{-4}$, $\rho = 10^{-5}$ 라 하자. 식 (3)의 괄호 안은

$$N = 10^6 : 10^{-6} + 10^{-5} = 1.1 \times 10^{-5}, \quad N = 10^7 : 10^{-7} + 10^{-5} = 1.01 \times 10^{-5}.$$

리드를 10배 늘려도 분산은 약 8%만 줄어든다. 반면 라이브러리를 하나 더 추가하면 평균의 분산이 절반이 된다. BARCS가 자유도를 리드가 아니라 라이브러리 수에서 가져오는 이유가 바로 이것이다.

3 회귀 모델

라이브러리 i 의 가이드 g 에 대해

$$K_{gi} \mid N_i \sim \text{BetaBinomial}(N_i, \mu_{gi}, \rho_g), \quad \text{logit}(\mu_{gi}) = \mathbf{x}_i^\top \boldsymbol{\beta}_g. \quad (4)$$

모든 가이드는 자기만의 계수 $\boldsymbol{\beta}_g$ 와 과분산 ρ_g 를 가진다. 설계 벡터 $\mathbf{x}_i$ 는 R 모델 행렬의 한 행이므로 $\sim \text{dose} + \text{batch}, \sim \text{replicate} + \text{time}, \sim \text{knockout} * \text{treatment}$ 모두 쓸 수 있다.

계수의 해석. β_{gd} 는 다른 열을 고정했을 때 예측변수 d 가 한 단위 변할 때 가이드의 라이브러리 내 비율의 로그오즈 변화량이다. 가이드 비율은 매우 작으므로 $\text{logit}(\mu) \approx \log \mu$ 이고, 따라서 β_{gd} 는 x_d 한 단위당 풍부도의 로그 배수 변화(log fold change)와 거의 같다.

대비(contrast). 임의의 선형결합 $\mathbf{c}^\top \boldsymbol{\beta}$ 를 검정할 수 있다. 예를 들어 두 처리군 사이의 차이를 검정한다(bb_contrast()).

4 추정: 실현가능 IRLS

BARCS는 각 가이드를 따로, 실현가능(feasible) 반복 재가중 최소제곱(IRLS)으로 적합한다. 가이드 첨자를 생략하고 현재의 $\boldsymbol{\beta}$ 와 ρ 에서

$$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}, \quad \mu_i = \frac{e^{\eta_i}}{1 + e^{\eta_i}}, \quad (5)$$

$$z_i = \eta_i + \frac{Y_i - \mu_i}{\mu_i(1 - \mu_i)}, \quad w_i = \frac{N_i \mu_i (1 - \mu_i)}{1 + (N_i - 1)\rho}. \quad (6)$$

갱신은 작업 반응(working response)에 대한 가중 최소제곱이다: $\hat{\boldsymbol{\beta}}_{\text{new}} = (X^\top W X)^{-1} X^\top W \mathbf{z}$.

ρ 의 추정. 각 적합 평균에서 ρ 는 피어슨 추정방정식

$$\sum_{i=1}^m \frac{(K_i - N_i \hat{\mu}_i)^2}{N_i \hat{\mu}_i (1 - \hat{\mu}_i) \{1 + (N_i - 1)\hat{\rho}\}} = m - q \quad (7)$$

의 해이다. 여기서 m 은 라이브러리 수, q 는 계수의 수이다. 좌변은 ρ 에 대해 감소하며, 세 가지 경우가 있다.

1. 이항 피어슨 통계량($\rho = 0$)이 이미 $m - q$ 이하이면 과분산이 없는 것이므로 $\hat{\rho}$ 를 0으로 자른다.

2. 그렇지 않으면 수치적으로 근을 찾는다.
3. ρ 를 상한까지 올려도 통계량이 $m - q$ 보다 크면 $\hat{\rho}$ 를 상한으로 두고, 남은 피어슨 스케일을 공분산에 곱한다.

계수 갱신과 과분산 갱신을 번갈아 하면서 계수 변화가 허용오차보다 작아지면 멈춘다.

가중치는 포화된다. $\rho > 0$ 이면 $N_i \rightarrow \infty$ 일 때 $w_i \rightarrow \mu_i(1 - \mu_i)/\rho$ 이다. 라이브러리의 가중치는 깊이에 따라 끝없이 커지지 않는다. 이는 식 (3)을 적합 쪽에서 본 것이다.

패키지에서는

`bbreg()`는 가이드 하나를 적합하고, `bb_screen()`은 리드 수 행렬의 모든 행을 (병렬로도) 적합한다. 가중 교차곱은 `RcppArmadillo`로 C++에서 계산한다.

5 가이드 하나에 대한 추론

수렴했을 때 공분산은 $\widehat{\text{Cov}}(\hat{\beta}) = (X^T \widehat{W} X)^{-1}$ 이고, 계수 j 에 대해

$$t_j = \frac{\hat{\beta}_j}{\sqrt{\widehat{\text{Cov}}_{jj}}} \sim t_{m-q} \quad (8)$$

이다. 기준 자유도는 $m - q$, 즉 독립 라이브러리 수에서 계수 수를 뺀 값이다. 총 리드 수는 들어가지 않는다.

예제: Cas13 스크린의 자유도

각 세포주에는 라이브러리 6개(0, 7, 14일 $\times$ 반복 2개)가 있고, 모델 $\sim \text{replicate} + \text{time}$ 의 계수는 3개(절편, 반복, 시간)이다. 따라서 각 가이드의 잔차 자유도는 $6 - 3 = 3$ 이다. 자유도 3으로 추정된 분산은 매우 불안정하며, 이것이 다음 절의 동기가 된다.

t 분포는 정규분포보다 꼬리가 두껍지만 $\hat{\rho}$ 를 알려진 값으로 취급한다. 과분산 추정의 불확실성을 정확히 보정하는 것은 아니며, 실제로는 조절 (moderation)과 음성 대조군이 안전장치 역할을 한다.

6 과분산 조절(기본으로 켜짐)

6.1 아이디어

잔차 자유도가 3이면 어떤 가이드는 우연히 조용해 보여 표준오차가 아주 작아지고, 어떤 가이드는 시끄러워 보여 표준오차가 커진다. 조절은 `limma`와 `edgeR`처럼 각 가이드의 분산을 라이브러리 전체의 추세 쪽으로 수축시킨다.

6.2 절차

1. 원래 팽창(inflation). $\nu = m - q$, $s_g^2 = Q_g^{(0)}/\nu$ 로 둔다. $Q_g^{(0)}$ 는 이항 모델에서의 가이드 피어슨 통계량이다. $\hat{\rho}$ 와 달리 s_g^2 는 잘리지 않으므로 χ_ν^2/ν 에 스케일을 곱한 것처럼 행동한다.
2. 추세. $\log s_g^2$ 를 로그 평균 CPM에 대해 `lowess`로 적합한다 (span 0.5). 적합값을 $\log s_{\text{trend},g}^2$ 라 한다.

3. 사전 자유도(Smyth 2004). $e_g = \log s_g^2 - \log s_{\text{trend},g}^2 - \psi(\nu/2) + \log(\nu/2)$ 로 둔다. ψ 는 디감마 함수이다. 그리고

$$\text{초과분산} = \widehat{\text{Var}}(e_g) - \psi'(\nu/2)$$

를 계산한다. 초과분산 > 0 이면 $\psi'(d_0/2) = \text{초과분산}$ 을 d_0 에 대해 풀고, 아니면 $d_0 = \infty$ (완전 수축)로 둔다.

4. 사전 스케일. $s_{0g}^2 = \exp\{\log s_{\text{trend},g}^2 + \bar{e} + \psi(d_0/2) - \log(d_0/2)\}$.

5. 사후값.

$$\tilde{s}_g^2 = \frac{\nu s_g^2 + d_0 s_{0g}^2}{\nu + d_0}. \quad (9)$$

6. 재스케일. 적합된 표준오차는 이미 $\max(1, s_g^2)$ 를 반영하므로

$$\text{SE}_{g,\text{mod}} = \text{SE}_g \sqrt{\tilde{s}_g^2 / \max(1, s_g^2)}, \quad t_{g,\text{mod}} = \hat{\beta}_g / \text{SE}_{g,\text{mod}}, \quad \text{자유도} = \nu + d_0.$$

계수 $\hat{\beta}_g$ 는 절대 바뀌지 않는다. 바뀌는 것은 표준오차와 기준분포뿐이다.

예제: 가이드 하나

$\nu = 3$, $s_g^2 = 4$, 사전값 $s_{0g}^2 = 1.5$, $d_0 = 12$.

$$\tilde{s}_g^2 = \frac{3(4) + 12(1.5)}{15} = 2.0, \quad \text{재스케일} = \sqrt{2/4} = 0.71, \quad \text{자유도} = 15.$$

시끄러운 가이드의 표준오차가 29% 줄고, 검정은 t_3 대신 t_{15} 를 기준으로 한다. 반대로 $s_g^2 = 0.5$ 인 가이드는 사전값 쪽으로 올라가서 거짓 확신을 막는다.

패키지에서는

`bb_screen(moderate = NULL)`은 사용 가능한 가이드가 50개 이상이면 조절한다. `moderate = FALSE`로 끌 수 있다. 옵션: `trend = FALSE`는 상수 하나로 수축, `one_way = TRUE`는 분산을 올리지만 함, `borrow_df = FALSE`는 자유도를 ν 로 유지한다. 이미 조절된 결과는 다시 조절할 수 없다.

왜 중요한가. Cas13 스크린에서 조절은 필수 유전자 평균정밀도를 0.838에서 0.876으로 올려 limma-voom, edgeR-QL과 같은 수준으로 만들었고, 모든 세포주에서 개선되었다.

7 분모: 계수는 무엇에 대한 상대값인가

7.1 라이브러리 전체 총합과 조성 이동

N_i 를 분모로 쓰면 β 는 라이브러리 내 비율의 변화를 뜻한다. 탈락(dropout) 스크린처럼 많은 가이드가 줄어들면, 절대량이 그대로인 가이드도 살아남은 것만으로 비율이 커진다. 그러면 귀무 가이드의 계수가 양수가 되고, t 통계량도 커질 수 있다.

7.2 대조군 기반 총합

`barcs_control_totals()`는 선택한 대조군 집합 C 가 모든 라이브러리에서 일정한 비율을 갖도록 총합을 만든다.

$$N_i^{\text{ctrl}} = \text{round}\left(\frac{\sum_{g \in C} K_{gi}}{\sum_{g \in C} K_g} \bar{N}\right), \quad \text{필요하면 } N_i^{\text{ctrl}} \geq \max_g K_{gi} \text{가 되도록 올림.} \quad (10)$$

그러면 계수는 대조군에 대한 상대 풍부도를 뜻한다.

예제: 대조군 총합

라이브러리 2개, 대조 가이드 2개는 두 라이브러리 모두에서 각각 500 리드, 히트 가이드 1개는 라이브러리 1에서 1,000, 라이브러리 2에서 100 리드라 하자. 전체 총합은 2,000과 1,100(평균 1,550)이다. 대조군 총합은 두 라이브러리 모두 $1000 \times 1550 / 1000 = 1550$ 이므로 대조군은 같은 비율을 유지하고, 히트의 감소는 대조군에 대해 측정된다.

대조군 선택. Non-targeting 가이드는 DNA를 자르지 않고, safe-harbor 가이드는 자르지만 유전자를 맞히지 않는다. Safe-harbor로 정규화하면 공통적인 절단 반응이 흡수된다. 총합을 만드는 데 쓴 가이드는 결과를 평가하는 데 쓰지 않아야 한다.

8 음성 대조군 보정

모델 가정이 깨지면(예: 한 공여자의 FACS 빈들이 같은 세포를 나눠 가짐) 귀무 t 통계량의 분포가 너무 넓어진다. `bb_calibrate_controls()`는 음성 대조군에서 추정된 하나의 배율로 모든 t 통계량을 재조정한다.

- `tail_quantile`: 배율 = $Q_{0.95}(|t_{\text{대조}}|) / t_{\nu, 0.975}$;
- `qq_slope`: 0.50–0.95 구간에서 대조군 분위수를 t 분위수에 대해 원점을 지나도록 회귀한 기울기 (변동이 더 작음);

그 다음 배율 $\leftarrow \max(1, \text{배율})$ 로 두므로, 보정은 검정을 더 보수적으로만 만든다. 표준오차에는 배율을 곱하고 t 통계량은 나누며, 추정치는 바뀌지 않는다.

예제: 꼬리 배율

대조군 $|t|$ 의 95번째 백분위수가 3.5, $\nu = 4$ 라 하자. $t_{4, 0.975} = 2.776$ 이므로 배율은 $3.5 / 2.776 = 1.26$ 이고, 모든 t 를 1.26으로 나눈다.

정직한 평가. 같은 대조군으로 배율을 정하고 그 대조군으로 귀무 비율을 보고하면, 5%라는 결과는 정의상 자동으로 나온다. 그래서 IL2RA 분석은 5겹 교차적합을 쓴다. 각 대조군은 나머지 4개 겹에서 추정된 배율로 평가된다.

9 가이드에서 유전자로

9.1 방향성 Stouffer

유전자 g 의 j 번째 유효 가이드에 대해, 양측 p 값을 부호가 있는 정규 점수로 되돌린 뒤 더한다.

$$z_{gj} = \text{sign}(\hat{\beta}_{gj}) \Phi^{-1}\left(1 - \frac{p_{gj}}{2}\right), \quad Z_g = \frac{\sum_{j=1}^{m_g} z_{gj}}{\sqrt{m_g}}, \quad p_g = 2\Phi(-|Z_g|). \quad (11)$$

방향이 같은 가이드는 서로 강화하고, 반대인 가이드는 상쇄된다. 보고하는 유전자 효과는 가이드 계수의 중앙값으로, 극단적인 가이드 하나에 휘둘리지 않는다. 유전자 p 값은 이후 BH로 보정한다.

9.2 독립성 문제

$\sqrt{m_g}$ 는 독립인 표준정규변수 m_g 개 합인 표준편차이다. 그런데 한 유전자의 가이드들은 모든 라이브러리를 공유하므로, 잡음을 공유하면 귀무 점수 사이에 양의 상관 r 이 생기고

$$\text{Var}\left(\sum_j z_{gj}\right) = m_g + m_g(m_g - 1)r \quad (12)$$

가 된다. BARCS는 대신 이 값의 제곱근으로 나눈다.

$$Z_g^c = \frac{\sum_j z_{gj}}{\sqrt{m_g + m_g(m_g - 1)\hat{r}}}. \quad (13)$$

예제: 상관이 하는 일

가이드 5개의 점수 합이 $\sum z = 5.59$ (각 $z \approx 1.12$)라 하자. 보정 전 $Z = 5.59/\sqrt{5} = 2.5$, $p = 0.012$ 이다. $r = 0.4$ 이면 분산은 $5 + 5 \cdot 4 \cdot 0.4 = 13$ 이고 $Z^c = 5.59/\sqrt{13} = 1.55$, $p = 0.12$ 로 더 이상 유의하지 않다.

9.3 실제 신호에 속지 않고 r 을 추정하기

1. 각 가이드의 라이브러리별 피어슨 잔차 벡터를 길이 1로 정규화한다.
2. 가이드가 2개 이상인 각 유전자에서 쌍별 내적(상관)의 평균을 구하고, 이를 유전자마다 같은 가중치로 평균한다(큰 대조군 “유전자”가 지배하지 않도록).
3. 서로 다른 유전자의 가이드 쌍(결정적으로 정한 쌍)에 대해서도 같은 값을 구한다. 이 기준선은 라이브러리 전체가 공유하는 상관을 제거한다.
4. $\hat{r} = \min\{1, \max(0, \text{유전자 내} - \text{유전자 간})\}$.

핵심 개념

잔차는 적합된 평균이 실제 유전자 효과를 포함한 모든 설계 효과를 흡수하고 남은 것이다. 따라서 모든 가이드가 강하게 감소하는 유전자라도 잔차는 상관되지 않는다. 가이드들이 공유하는 잡음만 잔차 상관을 만든다. 그래서 이 보정은 진짜 히트에 불이익을 주지 않는다.

$r = 0.4$ 인 시뮬레이션에서 보정 후 유전자 수준 1종 오류는 0.018–0.052였고, 보정 전에는 최대 0.262였다. 분석한 실제 스크린에서 $\hat{r}$ 은 0.008–0.026이어서 보정에 따른 변화는 작았다.

9.4 실험적 대안

네 가지 다른 요약은 검정 대신 효과 크기를 합친다: `bb_gene_normal()`, `bb_gene_consistency()`, `bb_gene_partial_pool()`, `bb_gene_eb_moderate()`. 시뮬레이션 FACS 벤치마크에서 Stouffer보다 유전자 순위가 나빴으므로 민감도 분석용으로만 남겨 두었다.

10 벤치마크에서 성공을 측정하는 방법

지표	의미
AUROC	임의의 양성인 임의의 음성보다 높은 순위일 확률.
평균정밀도(AP)	각 참양성 순위에서의 정밀도 평균. 목록 상단에 민감.
5% 귀무 FPR에서의 재현율	귀무 유전자의 5%만 넘는 점수 위에 있는 양성의 비율. 보정 정도와 무관.
FDR 0.10에서의 재현율	방법 자체의 명목 FDR에서 검출된 양성 비율. 보정에 의존.
실현 FDP	정답을 알 때 검출 중 거짓의 비율.
대리 귀무	귀무로 가정한 유전자(예: 발현되지 않는 lncRNA). 불완전 하므로 귀무 비율은 진단용.

주요 결과 (BARCS 0.2.0).

벤치마크	BARCS	비교
Cas13 AP	0.876	limma 0.876, edgeR 0.874, MAGeCK 0.877
Cas13 FDR 0.10 재현율	0.767	0.692–0.767
IL2RA 검증된 조절인자	23/26, 61개 검출	MAGeCK 17/26, 72개 검출
CRISPulator F1 (조절)	0.847	조절 전 0.811
귀무 그리드, 상관된 가이드	0.018–0.052	보정 전 최대 0.262
A375 FDR 0.05 재현율	0.883	MAGeCK 0.710

11 유의할 한계

- 독립 라이브러리. 한 공여자의 FACS 빈들과 한 배양에서 반복 수확한 라이브러리는 서로 종속이다. 공여자 지시변수는 평균을 보정하고 대조군은 잘못된 보정을 바로잡지만, 종속성 자체를 모델링하지는 않는다.
- 대입(plug-in) 과분산. t 기준분포는 $\hat{\rho}$ 를 알려진 값으로 취급한다. 조절이 이 근사를 줄이지만 없애지는 않는다.
- 가능도와 맞는 리드 수. Cas13 벤치마크는 정규화·배치보정된 값을 정수로 반올림해 사용했다. 원시 리드 수로 다시 분석하는 것이 더 강한 검증이다.
- 분모 선택. 전체 라이브러리 기준 계수와 대조군 기준 계수는 서로 다른 질문에 답한다. 결과를 보기 전에 정해야 한다.

12 파이프라인 한눈에 보기

1. `barcs_quant()`: FASTQ $\rightarrow$ counts, totals.

2. 선택: `barcs_control_totals()`로 기준 선택.
3. `bb_screen()`: 가이드별 베타-이항 회귀, t 검정, 과분산 조절, 잔차 상관 $\hat{r}$.
4. 선택: `bb_calibrate_controls()`로 음성 대조군 배율.
5. `bb_gene_stouffer()`: 상관을 반영한 유전자 통계량, 중앙값 효과, BH FDR.

13 퀴즈

가장 알맞은 답을 하나 고르시오. 해설이 포함된 정답은 다음 페이지부터 있다.

Q1. BARCS에서 라이브러리 i 의 총합 N_i 는 무엇이어야 하는가?

- (A) 가이드별 리드 수의 중앙값
- (B) 리드 수가 적은 가이드를 제거한 뒤의 합
- (C) 가이드 필터링 전에 기록한 매핑된 가이드 리드 전체 총합
- (D) FASTQ 파일의 리드 수

Q2. 가이드 리드 수의 베타-이항 분산은 $N\mu(1-\mu)\{1+(N-1)\rho\}$ 이다. $\rho=0$ 으로 두면?

- (A) 분산이 0
- (B) 이항분포 분산
- (C) 포아송 분산
- (D) 음이항분포 분산

Q3. $\mu=10^{-4}$, $\rho=10^{-5}$ 일 때 시퀀싱 깊이를 10^6 에서 10^7 리드로 늘리면 관측 비율의 분산은 대략 얼마나 줄어드는가?

- (A) 8%
- (B) 50%
- (C) 90%
- (D) 0%

Q4. BARCS 가이드 검정의 잔차 자유도는?

- (A) 독립 라이브러리 수 - 계수 수
- (B) 유전자당 가이드 수 - 1
- (C) 30으로 고정
- (D) 총 리드 수 - 계수 수

Q5. 모델 $\text{logit}(\mu_{gi}) = \mathbf{x}_i^\top \boldsymbol{\beta}_g$ 에서 계수 β_{gd} 의 가장 알맞은 해석은?

- (A) 가이드의 과분산
- (B) 가이드가 필수일 확률
- (C) x_d 한 단위당 원시 리드 수의 변화
- (D) 다른 열을 고정했을 때 x_d 한 단위당 가이드 풍부도의 대략적인 로그 배수 변화

Q6. $\rho > 0$ 에서 $N_i \rightarrow \infty$ 일 때 IRLS 가중치 $w_i = N_i\mu_i(1-\mu_i)/\{1+(N_i-1)\rho\}$ 는?

- (A) 끝없이 커진다
- (B) 0으로 간다
- (C) $\mu_i(1-\mu_i)/\rho$ 로 간다
- (D) N_i 와 같다

Q7. 가이드의 이항 피어슨 통계량이 이미 $m-q$ 보다 작으면 BARCS는 $\hat{\rho}$ 를 무엇으로 두는가?

- (A) 0
- (B) 라이브러리 전체 중앙값
- (C) $1/(m - q)$
- (D) 상한값

Q8. Cas13 세포주 하나에 라이브러리가 6개이고 모델이 $\sim \text{replicate} + \text{time}$ 이다. 각 가이드의 잔차 자유도는?

- (A) 5
- (B) 3
- (C) 4
- (D) 2

Q9. 과분산 조절이 바꾸는 것은?

- (A) 라이브러리 총합
- (B) 표준오차와 기준 자유도 (단, $\hat{\beta}_g$ 는 그대로)
- (C) 가이드-유전자 배정
- (D) 계수 추정치 $\hat{\beta}_g$

Q10. 조절은 각 가이드의 로그 분산 팽창을 무엇 쪽으로 수축시키는가?

- (A) 전체 가이드에 대한 로그 평균 CPM의 lowess 추세
- (B) 0
- (C) 음성 대조군의 팽창만
- (D) 라이브러리에서 가장 큰 팽창

Q11. 사전 자유도 d_0 는 어떻게 추정하는가?

- (A) 4로 고정된 상수
- (B) 리드 수에 대한 최대가능도
- (C) 필수 유전자에 대한 교차검증
- (D) 디감마·트라이감마 함수를 쓰는 Smyth(2004)의 scaled- F 적률법

Q12. $\nu = 3$, $s_g^2 = 4$, $s_{0g}^2 = 1.5$, $d_0 = 12$ 일 때 조절된 팽창 $\hat{s}_g^2$ 는?

- (A) 2.75
- (B) 4.0
- (C) 2.0
- (D) 1.5

Q13. 조절이 $\hat{\rho}_g$ 대신 $s_g^2 = Q_g^{(0)}/\nu$ 를 쓰는 이유는?

- (A) $\hat{\rho}_g$ 는 시퀀싱 깊이에만 의존한다
- (B) s_g^2 는 설계를 무시한다
- (C) `bb_screen()`이 $\hat{\rho}_g$ 를 저장하지 않는다
- (D) $\hat{\rho}_g$ 는 0에서 잘리므로 스케일된 χ^2 처럼 행동하지 않는다

- Q14.** 기본 설정에서 `bb_screen()`은 언제 과분산을 조절하는가?
- (A) 사용자가 음성 대조군을 제공할 때
 - (B) 설계에 그룹이 세 개 이상일 때
 - (C) 사용 가능한 가이드가 50개 이상일 때
 - (D) 항상, 가이드가 5개뿐이어도
- Q15.** 전체 라이브러리 총합을 쓰는 탈락 스크린에서 귀무 가이드의 계수는 보통 어떻게 나타나는가?
- (A) 모든 가이드가 줄어들므로 음수
 - (B) 정의되지 않음
 - (C) 0 근처
 - (D) 살아남은 가이드의 라이브러리 내 비율이 커지므로 양수
- Q16.** `barcs_control_totals()`가 만드는 총합은?
- (A) 백만 리드당 수(CPM)로 정규화된 값
 - (B) 선택한 대조군 집합이 모든 라이브러리에서 일정한 비율을 갖도록 한 값
 - (C) 대조 가이드를 제외한 값
 - (D) FASTQ 리드 수와 같은 값
- Q17.** Non-targeting 대신 safe-harbor 가이드로 정규화하면?
- (A) 공통 절단 반응이 기준에 흡수된다
 - (B) 모든 조성 이동과 절단 효과가 사라진다
 - (C) 총합이 정수가 아니게 된다
 - (D) 아무 효과가 없다
- Q18.** `min_scale = 1`인 `bb_calibrate_controls()`는?
- (A) 검정을 더 관대하게만 만든다
 - (B) 검정을 더 보수적으로만 만든다(또는 그대로 둔다)
 - (C) 유전자 배정을 바꾼다
 - (D) 계수 추정치를 바꾼다
- Q19.** 대조군 $|t|$ 의 95번째 백분위수가 3.5, $\nu = 4$ ($t_{4,0.975} = 2.776$)이다. 꼬리 배율은 약?
- (A) 3.50
 - (B) 1.00
 - (C) 1.26
 - (D) 0.79
- Q20.** IL2RA 분석에서 대조군 보정에 5점 교차적합을 쓴 이유는?
- (A) 스크린에 공여자가 다섯 명이라서
 - (B) 계산을 빠르게 하려고
 - (C) 같은 대조군으로 배율을 추정하고 귀무 비율을 평가하면 5%가 정의상 자동으로 나오기 때문에

(D) 가이드 상관을 추정하려고

Q21. 방향성 Stouffer에서 가이드의 부호 있는 점수는?

- (A) $-\log_{10} p_{gj}$
- (B) 항상 $\hat{\beta}_{gj}/SE_{gj}$
- (C) $\text{sign}(\hat{\beta}_{gj}) \Phi^{-1}(1 - p_{gj}/2)$
- (D) $\Phi^{-1}(p_{gj})$

Q22. BARCS가 보고하는 유전자 효과는?

- (A) 가이드 계수의 평균
- (B) 가이드 계수의 중앙값
- (C) Stouffer Z
- (D) 가장 큰 가이드 계수

Q23. 귀무 가이드 점수 m 개가 각각 분산 1, 쌍별 상관 r 을 가지면 합의 분산은?

- (A) m
- (B) $m + m(m - 1)r$
- (C) $m^2 r$
- (D) $m(1 - r)$

Q24. 가이드 5개, $r = 0.4$ 이면 보정된 Stouffer 분모는 $\sqrt{5}$ 대신 $\sqrt{13}$ 이다. 보정 전 $Z = 2.5(p = 0.012)$ 는 대략?

- (A) $Z = 4.0, p < 0.001$
- (B) $Z = 1.55, p = 0.12$
- (C) $Z = 2.5, p = 0.012$
- (D) $Z = 0, p = 1$

Q25. BARCS가 유전자 내 상관을 잔차로 추정하는 이유는?

- (A) 실제 유전자 효과는 적합된 평균에 흡수되어 잔차 상관을 키우지 않지만, 공유 잡음은 키우기 때문에
- (B) 잔차는 설계에 의존하지 않으므로
- (C) 잔차는 항상 독립이므로
- (D) 잔차가 리드 수보다 작으므로

Q26. BARCS가 서로 다른 유전자 가이드 간 평균 상관을 빼는 이유는?

- (A) 가이드 길이를 보정하려고
- (B) $\hat{r}$ 을 음수로 만들려고
- (C) 서로 다른 유전자는 완벽하게 상관되어 있으므로
- (D) 정규화 인공물처럼 라이브러리 전체가 공유하는 상관을 제거하려고

Q27. 유전자 내 평균에서 각 유전자에 같은 가중치를 주는 이유는?

- (A) 추정치를 항상 0으로 만들려고
- (B) 가이드가 많은 유전자가 지배하도록
- (C) 필수 유전자를 무시하려고
- (D) 하나의 “유전자”로 묶인 큰 대조 가이드 집합이 추정치를 지배하지 못하도록

Q28. 분석한 실제 스크린에서 추정된 유전자 내 상관은?

- (A) 0.008–0.026으로, 보정에 따른 변화는 작았다
- (B) 모든 스크린에서 0.5보다 컸다
- (C) 약 0.4였다
- (D) 정의상 정확히 0이었다

Q29. 5% 경험적 귀무 위양성률에서의 재현율이 FDR 0.10에서의 재현율과 다른 점은?

- (A) 순위를 무시한다
- (B) 음성 대조군이 필요하다
- (C) 필수 유전자만 사용한다
- (D) 방법의 p 값이 얼마나 잘 보정되었는지에 의존하지 않는다

Q30. Cas13 벤치마크에서 BARCS가 버전 0.2.0에서 limma와 edgeR을 따라잡은 주된 이유는?

- (A) 7일차 라이브러리를 제거해서
- (B) 음이향 가능도로 바뀌서
- (C) 대조군 기반 총합을 써서
- (D) 가이드 간에 정보를 빌려오는 과분산 조절 덕분에

Q31. 한 공여자의 FACS 빈에 대한 설명으로 옳은 것은?

- (A) 분석 전에 합쳐야 한다
- (B) 이항 모델이 필요하다
- (C) 같은 세포를 나눠 가지므로 종속이며, 공여자 지시변수는 평균은 보정하지만 그 종속성은 모델링하지 않는다
- (D) 독립 라이브러리이므로 BARCS가 정확히 모델링한다

Q32. 실험적 유전자 요약(`bb_gene_partial_pool()` 등)을 남겨 둔 이유는?

- (A) `bb_screen()`에 필요하므로
- (B) 보정을 대체하므로
- (C) 벤치마크에서 유전자 순위가 가장 좋았으므로
- (D) 민감도 분석용이다. 시뮬레이션 FACS 벤치마크에서는 Stouffer가 유전자 순위를 더 잘 매겼다

14 정답 및 해설

- Q1. C. 분모는 실제로 시퀀싱한 라이브러리를 나타내야 한다. 필터링 후 다시 계산하면 남은 모든 가이드의 비율이 조용히 바뀐다(1절).
- Q2. B. $\rho = 0$ 이면 괄호가 1이 되어 이항분산 $N\mu(1 - \mu)$ 만 남는다.
- Q3. A. 괄호 $(1 - \rho)/N + \rho$ 가 1.1×10^{-5} 에서 1.01×10^{-5} 로, 약 8% 줄어든다. 생물학적 변동이 지배한다.
- Q4. A. $m - q$. 깊이는 라이브러리 내 정밀도에는 영향을 주지만 자유도는 늘리지 않는다.
- Q5. D. 가이드 비율이 매우 작아 로그오즈 $\approx$ 로그 비율이므로, 계수는 조건부 로그 배수 변화이다.
- Q6. C. 분모가 $N\rho$ 처럼 커지므로 가중치는 $\mu(1 - \mu)/\rho$ 에서 포화된다.
- Q7. A. 이항 이상의 과분산이 보이지 않으므로 $\hat{\rho}$ 를 0으로 자른다.
- Q8. B. $6 - 3 = 3$.
- Q9. B. 조절은 표준오차를 재조정하고 사전 자유도를 더한다. $\hat{\beta}_g$ 는 바뀌지 않는다.
- Q10. A. 사전값은 로그 평균 CPM에 대한 로그 팽창의 lowess 추세를 따른다(trend = FALSE면 상수).
- Q11. D. 중심화한 로그 팽창의 분산이 $\psi'(\nu/2)$ 를 넘는 양을 $\psi'(d_0/2)$ 와 맞춘다.
- Q12. C. $(3 \cdot 4 + 12 \cdot 1.5)/15 = 30/15 = 2.0$.
- Q13. D. 0에서 자르면 분포가 왜곡된다. 잘리지 않은 피어슨 팽창은 scaled- F 모델이 가정하는 χ^2_ν/ν 처럼 행동한다.
- Q14. C. 사용 가능한 가이드가 50개 미만이면 사전값을 믿을 만하게 추정할 수 없어, 강제하지 않는 한 조절을 건너뛰는다.
- Q15. D. 조성 이동: 필수 가이드가 빠지면 남은 가이드의 비율이 커져 귀무 계수가 양수 쪽으로 이동한다.
- Q16. B. 대조군 총합은 대조군의 비율을 고정하고, 평균 라이브러리 크기로 재조정된 뒤 반올림한다.
- Q17. A. Safe-harbor 가이드는 DNA를 자르므로, 이것으로 정규화하면 표적 효과에서 공통 절단 반응이 빠진다.
- Q18. B. 배율의 하한이 1이므로 검정통계량은 1 이상의 수로만 나뉜다.
- Q19. C. $3.5/2.776 = 1.26$.
- Q20. C. 따로 떼어 둔 대조군으로 평가해야, 배율을 정한 대조군으로 보정을 평가하는 순환 논리를 피할 수 있다.
- Q21. C. 양측 p 값을 정규 편차로 되돌리고 계수의 부호를 붙인다.
- Q22. B. 중앙값은 극단적인 가이드 하나에 강하다.
- Q23. B. 분산 항 m 개와 크기 r 인 공분산 항 $m(m - 1)$ 개의 합이다.

- Q24. B. $Z^c = 2.5\sqrt{5}/\sqrt{13} = 1.55$, $p = 0.12$.
- Q25. A. 잔차는 적합된 설계 효과를 제외하므로 공유 잡음만 잔차 상관을 만든다.
- Q26. D. 유전자 간 기준선은 특정 유전자에 고유하지 않은, 라이브러리 전체의 상관을 제거한다.
- Q27. D. 유전자마다 같은 가중치를 주면 큰 가상 유전자가 평균을 지배하지 못한다.
- Q28. A. 추정된 $\hat{r}$ 은 Cas13에서 0.008–0.026, IL2RA 0.011, Evers 0.011이었다.
- Q29. D. 대리 귀무로 위양성률을 경험적으로 고정하므로, p 값 보정과 무관하게 순위를 비교한다.
- Q30. D. 조절로 AP가 0.838에서 0.876으로 올랐다. 조절이 없으면 각 가이드의 분산은 자유도 3에만 의존한다.
- Q31. C. 빈들은 하나의 세포 풀을 나누므로 음의 종속이 있다. 음성 대조군 보정이 그로 인한 잘못된 보정을 바로잡고, Waterbear는 종속성을 직접 모델링한다.
- Q32. D. 민감도 분석용으로 남겼다. 대부분의 시뮬레이션 시나리오에서 Stouffer의 평균정밀도와 F1이 더 높았다.